POLITECNICO DI TORINO

Corso di Laurea in Ingegneria Matematica

Statistica Computazionale

Analisi Spazio-Temporale dei Dati COVID-19 in Italia: Modelli Bayesiani Gerarchici

Guarnaschelli Eleonora

Anno accademico 2024-2025

Indice

1 Introduzione **3**

2 Descrizione dei dati **4**
2.1 Caratteristiche del dataset 4
2.2 Scelta della variabile risposta 5
2.3 Giustificazione dell'introduzione dell'off-set 6
2.4 Giustificazione della struttura spaziale 6
2.5 Giustificazione della divisione in fasi e struttura temporale 7

3 Formulazione Modellistica **12**
3.1 Richiamo teorico 12
3.2 Descrizione del modello 13

4 Scelte Implementative **16**

5 Risultati e Criticità **19**
5.1 Previsioni 19
5.2 Stime dei parametri a posteriori 22
5.3 Analisi dei residui del processo temporale latente 24
5.4 Limiti del modello e miglioramenti futuri 27

1 Introduzione

In questa tesina si analizzano i dati relativi all'epidemia di COVID-19 in Italia a livello regionale, resi disponibili dal Dipartimento della Protezione Civile su GitHub (`https://github.com/pcm-dpc/COVID-19`). L'obiettivo principale è costruire un modello probabilistico che tenga conto delle dipendenze spaziali e temporali tra i dati, con lo scopo di descrivere l'andamento dei contagi e valutarne la capacità predittiva.
Dopo un'analisi preliminare volta a esplorare le caratteristiche strutturali del dataset, si è scelta come variabile risposta il logaritmo dei contagi tramite un approccio bayesiano spazio-temporale. Il modello proposto è di tipo gerarchico e combina una dinamica temporale modellata tramite un processo autoregressivo di ordine 1 (AR(1)) specifico per ciascuna delle 19 regioni italiane, con una componente spaziale latente rappresentata da un Gaussian Process che cattura la correlazione tra regioni geograficamente vicine. Inoltre, è stato introdotto un termine di offset per tener conto della popolazione residente, insieme a un effetto fisso giornaliero nella media dei log-contagi per modellare la stagionalità settimanale.
Il modello è stato implementato in linguaggio Stan e applicato separatamente a quattro diverse fasi dell'epidemia, con l'obiettivo di valutare in quale contesto risulti più adatto. Il confronto tra le fasi è stato effettuato considerando la media a posteriori dei parametri stimati, la qualità della convergenza delle catene MCMC, i tempi computazionali e la capacità predittiva del modello.
Infine, viene proposta un'analisi critica dei limiti del modello, con particolare attenzione alla complessità computazionale e all'assunzione di separabilità tra spazio e tempo. Sulla base di queste riflessioni, si delineano possibili miglioramenti futuri, volti a rendere il modello più efficiente e rappresentativo della complessità dei fenomeni osservati.

2 Descrizione dei dati

Il primo step coincide con un'analisi descrittiva dei dati, nell'ottica di trovare giustificazioni pausibili per la formulazione successiva del modello.

2.1 Caratteristiche del dataset

Il dataset utilizzato è contenuto nel file `dati-regioni/dpc-covid19-ita-regioni.csv` del repository. Per ciascuna regione italiana, sono disponibili dati giornalieri a partire dal 24 febbraio 2020. In particolare, durante il lavoro sono state selezionate 19 coordinate spaziali: sono state escluse infatti le isole di Sardegna e Sicilia perchè difficilmente si riesce a tener conto della dipendenza spaziale per loro. Dall'altro lato, le coordinate temporali disponibili sono un totale di 1781 giorni, ma si è scelto di analizzare i dati a partire dal 9 marzo 2020, data dell'inizio del lockdown in Italia, fino al 5 maggio 2023, data ufficiale del termine della pandemia a seguito della dichiarazione dell'Organizzazione mondiale della sanità, per un totale di 1153 coordinate temporali. Le variabili incluse nel dataset sono le seguenti:

- `data`: data di riferimento
- `denominazione_regione`: nome della regione
- `nuovi_positivi`: nuovi attualmente positivi (cioè la differenza tra i casi totali del giorno corrente e quelli del giorno precedente)
- `lat`: latitudine della regione
- `long`: longitudine della regione

Dopodichè, siccome la variabile di interesse concide con il numero di contagi giornalieri per ogni regione e le regioni risultano essere particolarmente differenti tra di loro in termini di numero di abitanti, per garantire la possibilità di un confronto dell'evoluzione dei contagi, è stata introdotta nel dataset originale una nuova colonna `popolazione`, contente i dati di popolazione residente al 31 dicembre 2021 per ogni regione stimati dall'ISTAT. Un'anteprima del dataset è mostrata in Figura 2.1.

data	denominazione_regione	nuovi_positivi	lat	long	popolazione
2022-04-29	Abruzzo	2160	42.35122	13.398438	1293941
2022-04-29	Basilicata	630	40.63947	15.805148	539999
2022-04-29	Calabria	1834	38.90598	16.594402	1812871
2022-04-29	Campania	6662	40.83957	14.250850	5575025
2022-04-29	Emilia-Romagna	5379	44.49437	11.341721	4459477
2022-04-29	Friuli Venezia Giulia	942	45.64944	13.768136	1211357
2022-04-29	Lazio	5595	41.89277	12.483667	5710272
2022-04-29	Liguria	1334	44.41149	8.932699	1508120
2022-04-29	Lombardia	7631	45.46679	9.190347	10035481
2022-04-29	Marche	1735	43.61676	13.518875	1501323
2022-04-29	Molise	407	41.55775	14.659161	296547
2022-04-29	P.A. Bolzano	357	46.49933	11.356624	532616
2022-04-29	P.A. Trento	438	46.06894	11.121231	540958
2022-04-29	Piemonte	3402	45.07327	7.680687	4241875
2022-04-29	Puglia	4223	41.12560	16.867367	3956430
2022-04-29	Toscana	3639	43.76923	11.255889	3645691
2022-04-29	Umbria	1142	43.10676	12.388247	859300
2022-04-29	Valle d'Aosta	82	45.73750	7.320149	125034
2022-04-29	Veneto	6121	45.43490	12.338452	4851851

Figura 2.1: Estratto del dataset utilizzato

2.2 Scelta della variabile risposta

La variabile risposta d'interesse coincide con il numero di nuovi positivi a livello regionale. In generale, quando si lavora con dati di conteggio, le distribuzioni comunemente utilizzate sono la Poisson e, in presenza di overdispersione, la Negative Binomial. Per indagare la presenza di overdispersione, si riportano di seguito media, varianza e loro rapporto per ciascuna regione:

Tabella 1: Media, varianza e rapporto varianza/media dei nuovi positivi per regione

denominazione_regione	media	varianza	rapporto
Abruzzo	571.80	762120.48	1332.83
Basilicata	173.92	74066.85	425.86
Calabria	552.32	605502.27	1096.30
Campania	2135.16	11397372.73	5337.94
Emilia-Romagna	1867.73	9543414.35	5109.63
Friuli Venezia Giulia	504.57	584533.90	1158.47
Lazio	2090.00	8387223.28	4013.02
Liguria	563.64	838522.96	1487.70
Lombardia	3600.28	37692254.23	10469.27
Marche	622.08	937271.21	1506.67
Molise	88.95	17169.69	193.02
P.A. Bolzano	254.99	177484.32	696.05
P.A. Trento	213.12	138562.06	650.17
Piemonte	1505.12	5995496.66	3983.40
Puglia	1345.02	4353249.93	3236.57
Toscana	1389.06	5590434.30	4024.62
Umbria	384.40	330764.14	860.47
Valle d'Aosta	44.36	6531.54	147.23
Veneto	2338.55	11517543.12	4925.08

Un'altra tecnica comunemente adottata, utile in generale anche per trattare serie temporali con varianza non stazionaria, consiste nell'applicare la trasformazione logaritmica alla variabile risposta. Pertanto, si considera la trasformazione $\log(\text{nuovi_positivi} + \epsilon)$, dove $\epsilon = 0{,}5$ è introdotto per evitare valori nulli (che produrrebbero $-\infty$ dopo la trasformazione). L'idea sarebbe quindi quella di modellare la variabile trasformata tramite una distribuzione normale. Per giustificare l'assunzione di normalità per il log-casi nel modello, si è confrontata la distribuzione empirica di $\log(\text{nuovi_positivi} + \epsilon)$ con una distribuzione normale con media e varianza stimate dai dati, per ciascuna regione. Nel complesso, si osserva che molte regioni italiane (come Abruzzo, Emilia-Romagna, Lombardia, Lazio, Toscana, Veneto, Liguria) mostrano istogrammi moderatamente simmetrici e visivamente simili a una distribuzione normale, anche se permangono lievi asimmetrie a destra (es. Calabria, Puglia) o code e picchi più accentuati. Al contrario, regioni con bassa numerosità di casi, come Molise, Basilicata e Valle d'Aosta, mostrano un'aderenza minore alla normale. Di seguito sono riportati alcuni esempi rappresentativi:

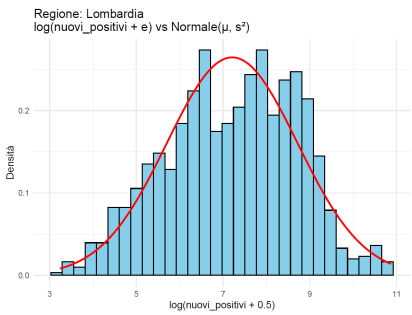

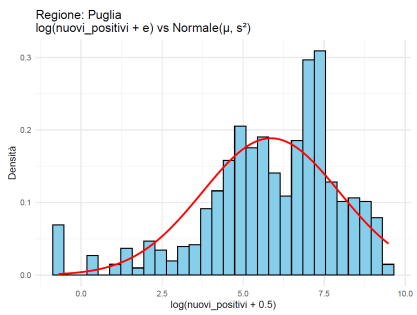

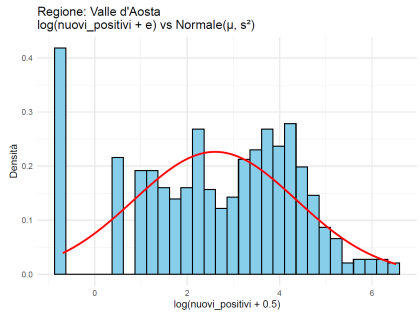

2.3 Giustificazione dell'introduzione dell'off-set

Per comprendere la distribuzione dei nuovi casi in funzione della popolazione regionale, in Figura 2.2 è riportato il confronto tra popolazione e casi totali cumulati.

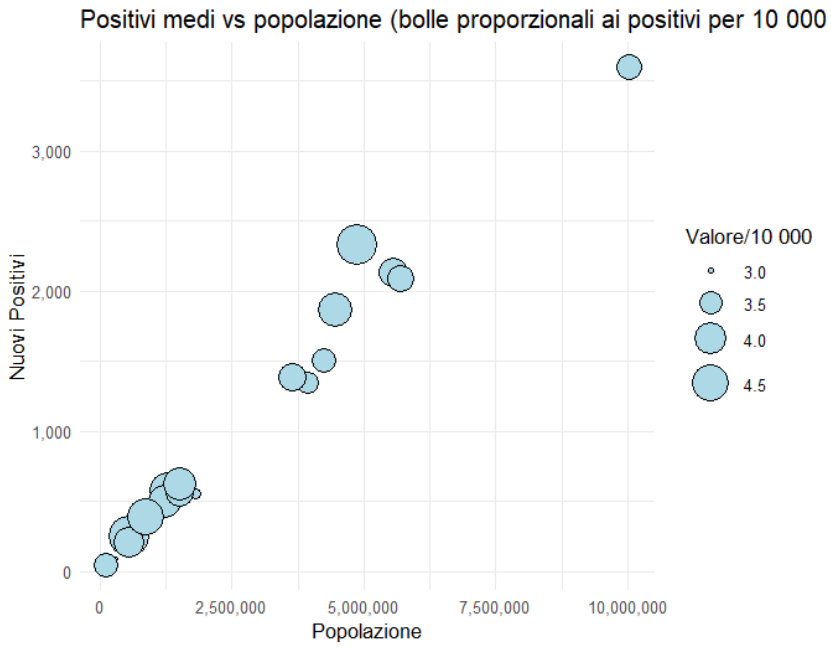

Figura 2.2: Confronto tra popolazione e numero totale di casi

Il grafico mostra che, all'aumentare della popolazione regionale (asse x), tende ad aumentare anche il numero medio di nuovi positivi giornalieri (asse y). Ciò evidenzia come le regioni più popolose registrino, in termini assoluti, un maggior flusso di casi semplicemente perché hanno più persone esposte. Regioni con popolazioni diverse non sarebbero quindi direttamente confrontabili se, per sviluppare i modelli successivi, non si tenesse conto della dipendenza del numero di positivi dal numero di abitanti di ogni regione. Pertanto nasce l'esigenza di introdurre come covariata nel modello l'offset logaritmico, che consente di considerare il tasso di nuovi positivi, confrontando direttamente l'"incidenza" o l'"intensità" del fenomeno sui diversi bacini demografici, senza che i risultati vengano distorti dalla sola grandezza della regione.

2.4 Giustificazione della struttura spaziale

La Figura 2.3 mostra una mappa tematica delle regioni italiane (escluse Sicilia e Sardegna), in cui il numero di casi è stato normalizzato per la popolazione regionale e moltiplicato per 10.000, in modo da ottenere un valore standardizzato: i cosiddetti casi per 10.000 abitanti. La scala cromatica utilizzata va dal nero (valori più bassi) al giallo (valori più elevati). Questa rappresentazione consente di confrontare equamente regioni con popolazioni diverse, come se tutte avessero la stessa dimensione demografica, facilitando l'identificazione di pattern spaziali nella diffusione del virus.

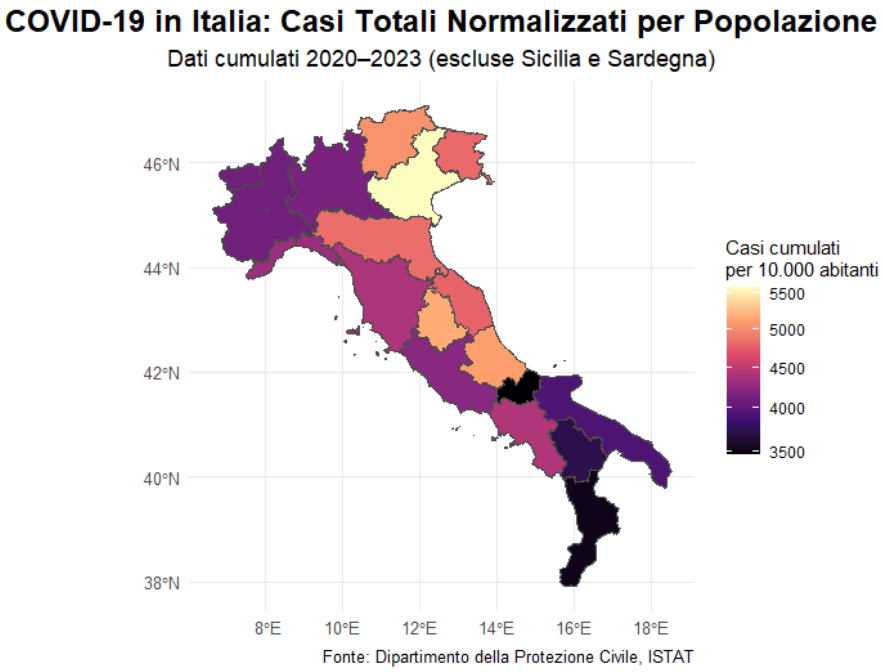

Figura 2.3: Mappa Tematica delle regioni italiane

Si osserva che le regioni con il numero di casi normalizzati più basso sono Molise, Calabria e Basilicata, tutte localizzate nel Sud Italia, seguite dalla Puglia. Al contrario, le regioni con i valori più elevati sono il Veneto, l'Umbria e l'Abruzzo, contraddistinte da tonalità arancioni chiare. È possibile individuare un pattern spaziale nei livelli di incidenza: regioni adiacenti tendono a presentare colorazioni simili. Ad esempio, Piemonte, Valle d'Aosta, Lombardia e Liguria condividono tonalità scure, così come Trentino-Alto Adige, Friuli Venezia Giulia e Veneto mostrano una prevalenza di colori più chiari, indicando valori più alti. Questa distribuzione potrebbe riflettere dinamiche comuni legate alla mobilità, alla densità abitativa o ad altri fattori socio-economici. Anche le regioni del Centro Italia, come Emilia-Romagna, Toscana, Marche, Abruzzo e Lazio, mostrano valori intermedi (tonalità prugna e viola chiaro), suggerendo un'incidenza moderata. Nel complesso, la mappa evidenzia come la diffusione del virus non sia stata uniforme sul territorio nazionale, ma abbia seguito un andamento in parte correlato alla prossimità geografica.

2.5 Giustificazione della divisione in fasi e struttura temporale

Un primo sguardo alla dinamica temporale complessiva dei contagi giornalieri è fornito in Figura 2.4. In particolare, l'immagine mostra l'andamento giornaliero dei nuovi casi di COVID-19 ogni 10.000 abitanti in Italia. La linea arancione rappresenta la media nazionale ottenuta come media tra regioni, mentre le linee grigie indicano l'andamento specifico di ciascuna regione.

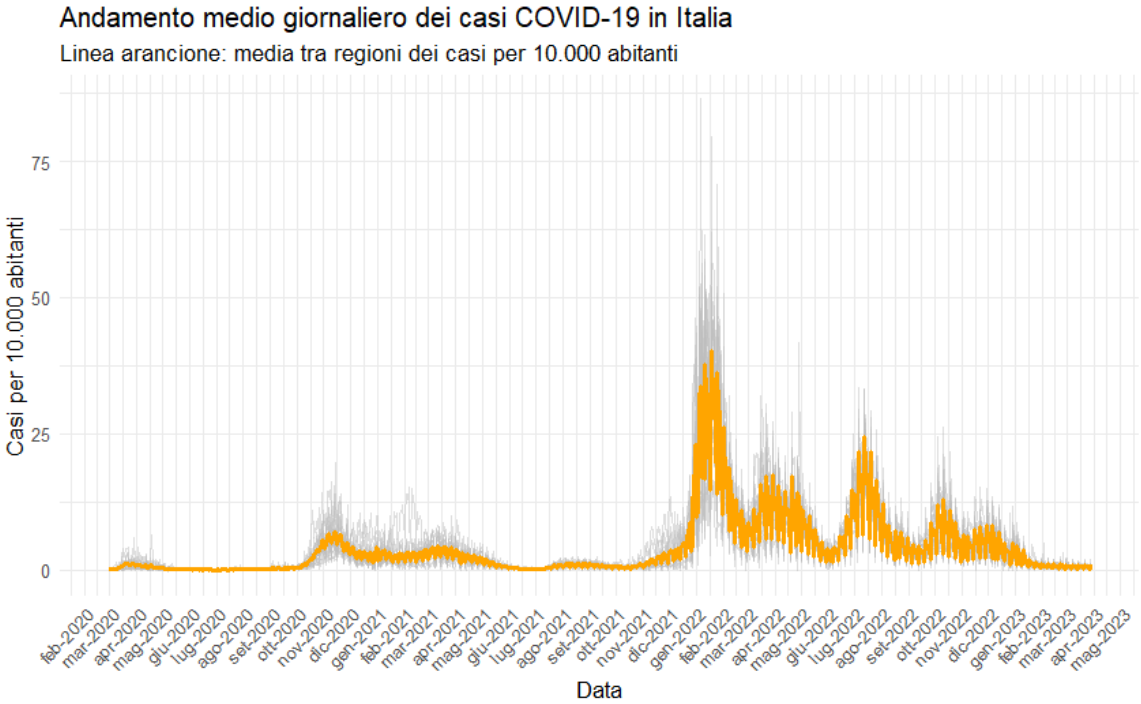

Figura 2.4: Serie temporale dei nuovi positivi a livello nazionale

È possibile osservare come l'epidemia abbia avuto un primo picco nei mesi di febbraio e marzo 2020 (prima ondata), seguito da un netto calo durante l'estate, grazie alle severe misure di contenimento come il lockdown nazionale. Una seconda ondata è chiaramente visibile tra ottobre e novembre 2020, probabilmente causata dall'allentamento delle restrizioni durante il periodo estivo. Una terza ondata è individuabile tra febbraio e marzo 2021, seguita da una progressiva riduzione dei casi favorita dall'introduzione della campagna vaccinale. Nel 2022 le diagnosi di positività sono state molto più numerose rispetto ai due anni precedenti, e con un numero di ondate molto maggiore: la prima tra gennaio e febbraio (associata alla variante Omicron), una seconda tra marzo e giugno, e diverse ondate minori tra l'autunno 2022 e l'inizio del 2023. Si riconosce indubbiamente una dipendenza temporale tra le osservazioni: giorni vicini tendono ad assumere valori vicini nella variabile d'interesse, motivo per cui è giustificato l'uso di modelli come AR(1) nella fase modellistica.
Da questa immagine emerge una prima problematica non particolarmente sconvolgente ma importante da gestire: l'evoluzione del Covid-19 non è stazionaria, nemmeno in senso debole, sull'intero periodo 2020-2023, ovvero media e varianza della serie non risultano invariati su tutto l'intervallo temporale, ma dipendono da dove viene osservato il processo. Sicuramente, una causa di ciò è riconducibile ai cambiamenti nel contesto normativo e sanitario, adottati in Italia nel corso degli anni per rispondere all'aumento progressivo dei casi. Pertanto, ipotizzare la stazionarietà sull'intero periodo 2020–2023 sarebbe inappropriato, in quanto il processo che genera i dati è necessariamente cambiato, date le numerose discontinuità causate da misure di prevenzione, varianti del virus e campagne vaccinali. Dunque, si è scelto di suddividere l'intero intervallo temporale in sei componenti principali, riportate nella Tabella 2, sulla base dei cambiamenti nel contesto normativo e sanitario.

Fase	Periodo	Misure principali	Razionale di stazionarietà
F1 – Lockdown nazionale	9 mar–3 mag 2020	DPCM 9/3: chiusura totale, scuole e attività ferme, stop spostamenti	Regole rigide e invarianti per 8 settimane
F2 – Sistema colori pre-vax	4 mag–31 dic 2020	Riaperture controllate; zone gialla/arancione/rossa; coprifuoco 22–5	Contesto normativo stabile senza vaccini, unica ondata "classica"
F3 – Avvio campagna vaccinale	1 gen–31 mar 2021	Prime somministrazioni; Green pass sperimentale; nessun lockdown	Cambiamento graduale, ma ritmo di immunizzazione ancora lento
F4 – Alpha → Delta	1 apr–30 nov 2021	Dominanza varianti Alpha e Delta; estensione GP; no coprifuoco	Regole stabili, ma dinamica guidata da varianti pre-Omicron
F5 – Ondata Omicron	1 dic 2021–31 mar 2022	Variante Omicron; massiva vaccinazione booster; fine restrizioni	Forte cambiamento virologico che giustifica separazione
F6 – Fine emergenza	1 apr 2022–5 mag 2023	Stop stato d'emergenza; aboliti colori, pass e coprifuoco; minime misure residue	Regole minime e stabili, stagionalità/varianti guidano la dinamica

Tabella 2: Suddivisione in sei fasi del contesto normativo COVID-19 in Italia, ciascuna compatibile con l'ipotesi di stazionarietà interna.

L'idea chiave alla base di questa tesina sarà dunque quella di formulare un unico modello spazio-temporale bayesiano per modellizzare l'evoluzione dei casi a livello regionale, addesstrarlo e fare previsione per ogni regione e per ogni fase e confronare i risultati ottenuti. Nella Figura sottostante 2.5 è presente il comportamento nazionale a livello di fase.

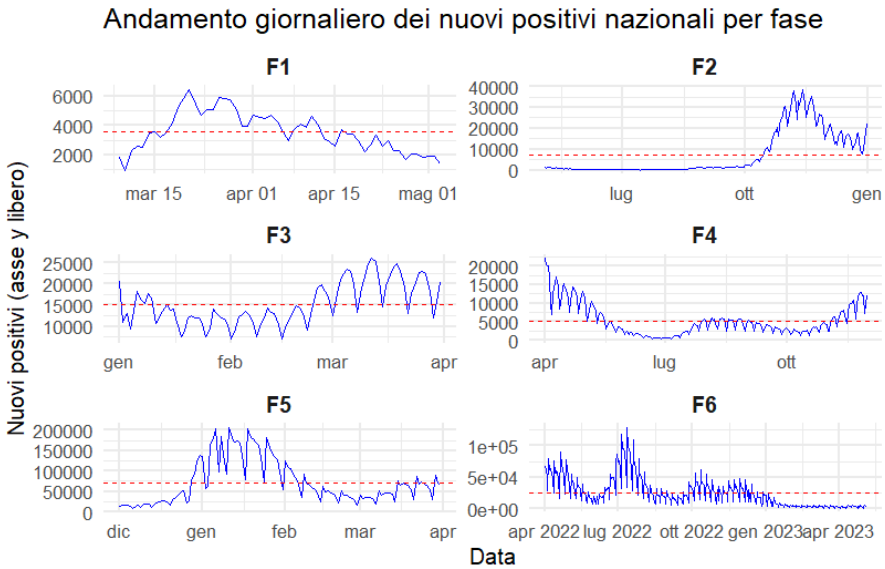

Figura 2.5: Serie temporale dei nuovi positivi a livello nazionale per fasi

Sebbene le fasi siano state definite sulla base delle principali modifiche nelle politiche sanitarie,

l'assunzione di stazionarietà statistica all'interno di ciascuna fase non risulta sempre giustificata dal punto di vista empirico. L'analisi visiva della serie giornaliera dei nuovi positivi, disaggregata per fase, mostra infatti che solo la Fase 1 presenta un comportamento chiaramente compatibile con la stazionarietà debole, con una media relativamente costante e fluttuazioni contenute nel tempo.
La Fase 3 evidenzia una forte stagionalità settimanale, ma la media rimane stabile e l'ampiezza delle oscillazioni non cresce, rendendola accettabile in prima approssimazione, soprattutto considerando che il modello include una intercetta γ_d per il giorno della settimana, che ne cattura la struttura periodica.
La Fase 4 mostra un andamento stagionale a lungo termine, caratterizzato da una progressiva riduzione dei casi nei mesi estivi seguita da un nuovo aumento in autunno, compatibile con la tipica stagionalità dei virus respiratori. Questo tipo di variazione, di natura ciclica ma su scala mensile/annuale, non è esplicitamente modellata nel nostro approccio e rappresenta una fonte di violazione dell'ipotesi di stazionarietà debole.
Le Fasi 5 e 6 mostrano invece cambiamenti strutturali marcati, incompatibili con un modello stazionario: rispettivamente un'esplosione iniziale seguita da rapido calo (F5) e un trend decrescente con picchi stagionali ricorrenti (F6).
La Fase 2 si colloca in posizione intermedia, risultando stabile nella parte iniziale ma mostrando un incremento netto dei contagi nella parte finale, che si riflette in un aumento sia della media che della varianza. Per tali motivi, si è scelto di escludere le Fasi 5 e 6 dall'analisi modellistica, poiché la loro evoluzione temporale richiederebbe strutture più flessibili, ad esempio tramite modelli con media mobile, stagionalità stocastiche o interazioni tempo-spazio non separabili.
A complemento dell'analisi visiva, si è inoltre indagata la struttura temporale della serie tramite l'autocorrelazione (ACF) e l'autocorrelazione parziale (PACF) a livello nazionale per ciascuna fase, i cui risultati sono riportati nella figura seguente.

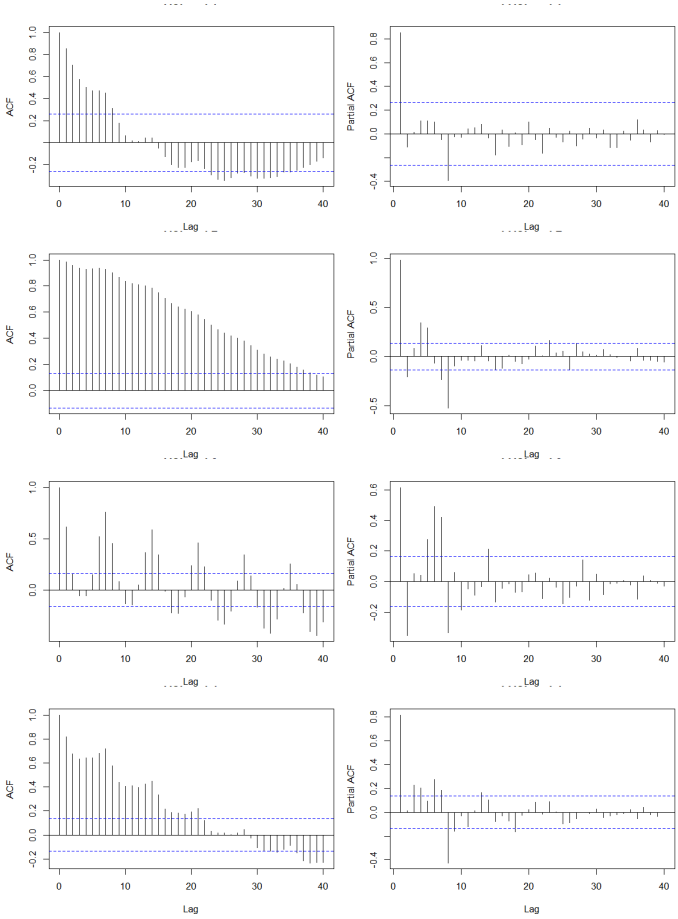

Figura 2.6: ACF e PACF dei nuovi positivi a livello nazionale per fasi

L'analisi delle funzioni ACF e PACF suggerisce che l'adozione di un modello AR(1) è ben giustificata nella fase 1, dove l'ACF decresce gradualmente e la PACF si annulla dopo il primo lag. Nelle fasi 2 e 4, l'AR(1) rappresenta una scelta parsimoniosa e semplificativa, in quanto la PACF mostra autocorrelazione residua anche ai lag successivi, segnalando una dinamica potenzialmente più complessa. La fase 3 evidenzia un comportamento marcatamente stagionale con periodicità settimanale: la presenza di picchi ricorrenti nella ACF ai lag 7, 14, 21 indica una struttura ciclica di tipo settimanale. Una spiegazione plausibile è legata a effetti sistematici del calendario, come la riduzione dell'attività diagnostica nei fine settimana e l'accumulo delle notifiche nei giorni successivi, in particolare il lunedì. Per tener conto di questa stagionalità regolare, il modello include un termine di intercetta γ_d associato al giorno della settimana. Questo permette di distinguere tra fluttuazioni deterministiche (dovute al calendario) e dipendenze stocastiche catturate dal processo AR(1). L'inclusione di γ_d rappresenta quindi una soluzione parsimoniosa, capace di adattarsi alla ciclicità osservata senza aumentare eccessivamente la complessità del modello. In tutte le fasi, l'adozione di un processo AR(1) uniforme per regione costituisce un compromesso tra parsimonia, stabilità della stima e confrontabilità inter-regionale. Eventuali sviluppi futuri potrebbero prevedere l'introduzione di strutture temporali più flessibili, come modelli ARMA(p,q) o componenti stagionali esplicite, per catturare in modo più accurato la memoria temporale e la complessità dinamica dei contagi nelle fasi più instabili.

3 Formulazione Modellistica

In questa sezione, in seguito a una breve introduzione teorica, viene presentato il modello spazio-temporale implementato per analizzare i dati e fare previsione.

3.1 Richiamo teorico

L'obiettivo è gestire 19 serie temporali, una per ciascuna regione italiana. Una serie temporale rappresenta una sequenza di osservazioni ordinate nel tempo, nelle quali si presume la presenza di dipendenza temporale: i valori futuri della variabile osservata possono dipendere, almeno parzialmente, dai valori passati. Per modellare questa dipendenza nel tempo, si utilizza un modello autoregressivo di ordine 1, noto come AR(1). Questo modello descrive l'evoluzione temporale di ciascuna regione in maniera indipendente, mentre per catturare la dipendenza spaziale tra regioni si farà uso di un processo gaussiano.

Un processo stocastico è una collezione di variabili aleatorie $\{X_t\}_{t \in T}$ indicizzate nel tempo, che si assume equispaziato (in questo caso, i giorni). Un processo stocastico può avere dimensione infinita ma si può dimostrare che è completamente caratterizzato dalla conoscenza della distribuzione di probabilità di ogni possibile insieme $(X_{t_1}, ..., X_{t_n})$ per ogni $t_1, t_2, ..., t_n \in T$ e ogni n (distribuzioni finito-dimensionali). Se tutte le distribuzioni finito-dimensionali del processo, ovvero la distribuzione congiunta di $(X_{t_1}, \ldots, X_{t_n})$ per ogni scelta di $t_1, \ldots, t_n \in T$, sono gaussiane, allora il processo è detto gaussiano. Affinché un processo possa essere descritto da un modello AR(1), è importante che sia stazionario, almeno in senso debole. Un processo si dice stazionario in senso debole di ordine s $\in N$ se per ogni $n \leq s$ naturale, e ogni n-tupla $(t_1, t_2, ..., t_n) \in T^n$ e per ogni scelta di h tale che $t_i + h \in T$ per ogni i = 1,2,.., n, abbiamo $E((X_{t_1}, ..., X_{t_n})) = E((X_{t_{1+h}}, ..., X_{t_{n+h}})) \leq \infty$. In pratica, si richiede spesso stazionarietà debole di ordine 2, ovvero che la media sia costante, che la varianza sia finita e che l'autocovarianza dipenda esclusivamente dalla distanza temporale (lag) e non dal tempo assoluto. Un processo $\{x_t\}$ segue un modello AR(1) se per ogni istante temporale t, la relazione tra x_t e il passato è data da:

$$x_t = \alpha x_{t-1} + w_t,$$

dove $\alpha \in \mathbb{R}$ è il parametro di autocorrelazione e $w_t \sim \mathcal{N}(0, \sigma^2)$ è una sequenza di rumori bianchi, cioè variabili casuali gaussiane indipendenti e identicamente distribuite con media nulla e varianza costante σ^2.

Il modello AR(1) è un processo di Markov del primo ordine, poiché la distribuzione condizionata di x_t dipende soltanto dal valore immediatamente precedente x_{t-1}, e non dall'intera storia passata. Una condizione fondamentale per la validità del modello è che $|\alpha| < 1$: in tal caso, il processo risulta stazionario e può essere riscritto, tramite sostituzioni ricorsive, come somma infinita pesata dei rumori bianchi:

$$x_t = \sum_{i=0}^{\infty} \alpha^i w_{t-i}.$$

Questa espressione mostra come il processo AR(1) sia una combinazione lineare di variabili gaussiane, e quindi anch'esso un processo gaussiano. Sotto queste condizioni, la media del processo risulta nulla, la varianza costante nel tempo ed espressa come:

$$\mathrm{Var}(x_t) = \gamma(0) = \frac{\sigma^2}{1 - \alpha^2},$$

mentre la covarianza al lag k, ovvero la dipendenza tra osservazione al tempo t e al tempo t+k, è data da:

$$\gamma(k) = \alpha^k \cdot \gamma(0) = \frac{\alpha^k \sigma^2}{1-\alpha^2},$$

mostrando un decadimento esponenziale della dipendenza nel tempo al crescere del lag.

Un caso particolare del modello AR(1) si verifica quando $\alpha = 1$, situazione nota come random walk o camminata aleatoria. In tal caso, il processo non è stazionario, poiché la varianza cresce all'aumentare del tempo.

Come già introdotto precedentemente, un processo $\{X(s) : s \in S\}$ è detto Gaussiano se le sue distribuzioni finito-dimensionali sono gaussiane. Per specificare il processo abbiamo bisogno di:

- una funzione media $m(s)$,
- una funzione di covarianza $C(s, s')$,

denotandolo come $X(s) \sim GP(m(s), C(s, s'))$.

Se assumiamo di aver osservato n punti del processo nelle coordinate $\{s_1, \ldots, s_n\}$, con $x_i = x(s_i)$, si ha:

$$x = (x_1, \ldots, x_n)' \sim N(\mu, \Sigma),$$

dove $[\mu]_i = m(s_i)$ e $[\Sigma]_{ij} = C(s_i, s_j)$. La matrice Σ deve essere definita positiva, il che implica che $C(s_i, s_j)$ sia una funzione definita positiva. Tra le funzioni di covarianza comunemente utilizzate si trovano quella esponenziale e la Cauchy.

In particolare verrà utilizzata quella esponenziale: $C(s_i, s_j) = \sigma^2 exp(-\phi * h_{ij})$, dove $h_{ij} = ||s_i - s_j||$ rappresenta la distanza tra le posizioni spaziali e $\phi > 0$ è il parametro di decay, che controlla la rapidità con cui la covarianza decresce con la distanza. Per lavorare con i processi gaussiani è necessario lavorare in uno spazio in cui è possibile calcolare una distanza scalare e che l'assunzione di stazionarietà sia soddisfatta.

Si osservi che, nel caso di osservazioni a intervalli regolari e in presenza di stazionarietà, un processo AR(1) può essere visto come un caso particolare di processo gaussiano con funzione di covarianza esponenziale.

3.2 Descrizione del modello

Definiamo:

- $s \in R = \{1, \ldots, 19\}$: indice spaziale (regioni)
- $t \in T = \{1, \ldots, 1153\}$: indice temporale (giorni)
- $d \in \{1, \ldots, 7\}$: indice del giorno della settimana

Indichiamo con $Y(s, t)$ la variabile aleatoria corrispondente al numero di nuovi positivi nella regione s al tempo t e con p(s) popolazione residente nella regione s. Per stabilizzare la varianza, utile in presenza di conteggi con overdispersione, e facilitare l'applicazione di un modello AR(1) stazionario, si considera la trasformazione logaritmica della variabile risposta: $y(s, t) = \log(Y(s, t) + \epsilon)$ con $\epsilon = 0.5$. Si noti che così facendo si passa da una variabile risposta di conteggio, quindi definita sui numeri naturali, a una variabile risposta definita sui numeri reali positivi.

Il modello bayesiano gerarchico spazio-temporale è definito come segue:

$$\begin{aligned} &y(s, t) \sim \text{Normal}(\mu_y, \sigma_y^2) \\ &\mu_y = \mu + \gamma_d + \sigma\left[\rho \cdot w_s(s) + (1-\rho) \cdot w_{s,t}(s, t)\right] + \beta * \log(p(s)) \end{aligned}$$

Le componenti additive principali del modello includono:

- μ: intercetta globale;
- γ_d: effetto fisso per il giorno della settimana, modellato tramite un vettore di dimensione 7 centrato ($\sum_{i=1}^{7} \gamma_i = 0$);
- $\beta * \log(\text{p(s)})$: offset logaritmico sulla popolazione regionale. Il parametro β è espressivo della relazione tra la popolazione regionale e il numero di positivi: se il suo valore medio a posteriori sarà circa 1, avremo la prova che la proporzionalità tra contagi e popolazione è lineare, se è maggiore di 1 allora la proporzionalità sarà esponenziale;
- $w_s(s)$: effetto spaziale, modellato come processo gaussiano multivariato a media nulla e covarianza esponenziale Σ;
- $w_{s,t}(s,t)$: effetto temporale, modellato come processo AR(1) differenziato per regione;
- σ: deviazione standard dell'effetto spazio-temporale;
- $\rho \in [0,1]$: peso che esprime quanta della variabilità del processo è spiegata dalla componente spaziale e quanta da quella temporale.

Il modello prevede dunque una combinazione pesata, con peso ρ, tra un processo AR(1) temporale indipendente per regione e un processo spaziale con kernel esponenziale in funzione della distanza geografica tra regioni. Gli effetti spazio-temporali presentano varianza σ, partizionata tra i due grazie al termine ρ. Dunque si può osservare che l'assunzione chiave dietro tale formulazione del modello, oltre a quelle alla base dei singoli processi spaziali e temporali, è la separabilità tra lo spazio e il tempo.

Prior debolmente informative sui parametri

$$
\begin{aligned}
\mu &\sim \mathcal{N}(0, 100) \\
\sigma^2 &\sim \text{IG}(1,1) \\
\alpha &\sim \mathcal{U}(-1,1) \\
\phi_s &\sim \mathcal{U}(\frac{3}{\text{max dist}}, \frac{3}{\text{min dist}}) \\
\rho &\sim \text{Beta}(1,2) \\
\gamma &\sim \mathcal{N}(0, 10) \\
\sigma_y^2 &\sim \text{IG}(1,1) \\
\beta &\sim N(0, 100)
\end{aligned}
$$

Effetto spaziale

L'effetto spaziale $w_s(s)$ segue un processo gaussiano con matrice di covarianza definita da:

$$\Sigma_{i,j} = \exp(-\phi_s \cdot D_{i,j})$$

dove D è la matrice delle distanze geografiche tra regioni e ϕ_s controlla la decrescita spaziale della correlazione. Si noti che con una covarianza esponenziale conviene assumere $\phi_s \in [\frac{3}{\text{max dist}}, \frac{3}{\text{min dist}}]$ poichè in questo modo si ha la garanzia che la matrice delle varianze e covarianzee sia sempre definita positiva.

Effetto temporale

L'evoluzione nel tempo dei contagi viene differenziata per ciascuna regione ed è descritta da un processo autoregressivo del primo ordine (AR(1)):

$$w(s,t) = \alpha * w(s,t-1) + r(s,t)$$

dove α rappresenta l'autocorrelazione temporale e gli $r(s,t) \sim N(0, \sigma_t^2)$ indipendenti e identicamente distribuiti rappresentano i rumori gaussiani. Si noti che gli AR(1) regionali sono indipendenti tra loro, ma omogenei nella struttura, poichè condividono lo stesso coefficiente di autocorrelazione α e la stessa varianza temporale σ_t^2.
Nella pratica, per simulare un AR(1) per ogni $s \in R$, si procederà come segue:

$$w(s,1) \sim \mathcal{N}\left(0, \frac{\sigma_t^2}{1-\alpha^2}\right)$$
$$w(s,t)|w(s,t-1) \sim \mathcal{N}\left(\alpha \cdot w(s,t-1), \sigma_t^2\right), \quad t = 2, \ldots, T$$

Sotto l'ipotesi di stazionarietà ($|\alpha| < 1$), la varianza marginale di un processo AR(1) è data da:

$$\mathrm{Var}[w_{s,t}(s,t)] = \frac{\sigma_t^2}{1-\alpha^2}$$

Vincolo sulla varianza del processo temporale

Per garantire che gli effetti spaziali e temporali nel modello siano confrontabili sulla stessa scala e assicurare l'identificabilità e interpretabilità del parametro ρ, imponiamo il seguente vincolo sulla varianza del processo AR(1) regionale:

$$\sigma_t^2 = 1 - \alpha^2$$

Infatti, affinché $\rho \in [0,1]$ sia interpretabile come un peso relativo tra l'effetto spaziale $w_s(s)$ e quello temporale $w_{s,t}(s,t)$, è necessario che i due effetti siano definiti sulla stessa scala (cioè abbiano varianza marginale comparabile). La varianza marginale del processo spaziale $w_s(s)$ è implicita nella matrice di covarianza Σ indotta dal kernel esponenziale, la cui diagonale è normalizzata a 1:

$$\Sigma_{i,i} = \exp(0) = 1$$

Pertanto, imporre $\mathrm{Var}[w(s,t)] = 1$ assicura che anche il processo temporale sia centrato sulla stessa scala. Dato che entrambi gli effetti sono successivamente moltiplicati per il parametro σ, la varianza complessiva dei termini spaziale e temporale sarà rispettivamente $\sigma^2\rho^2$ e $\sigma^2(1-\rho)^2$. In questo modo ρ modula realmente l'importanza relativa delle due componenti: uno ρ vicino a 1 implica dominanza dell'effetto spaziale, mentre uno ρ vicino a 0 enfatizza l'effetto temporale. In assenza di questo vincolo, il parametro ρ perderebbe significato, poiché la componente temporale assumerebbe una scala variabile in funzione di α, rendendo la combinazione convessa non interpretabile come un vero bilanciamento tra due effetti confrontabili.

4 Scelte Implementative

L'implementazione del modello gerarchico presentato nella Sezione 3 è stata effettuata in `Stan`, con interfaccia `cmdstanr` in `R`. La scelta di Stan è legata alla sua flessibilità e potenza nel trattare modelli bayesiani complessi, consentendo l'uso di vincoli e trasformazioni non banali e garantendo la possibilità di estensione del modello di partenza, tramite l'introduzione di nuovi effetti, senza modifiche eccessive. Di seguito è presente una descrizione dettagliata del codice implementato:

Struttura dati. Le osservazioni di training e test sono indicizzate per le regioni tramite (`region_train`, `region_test`), per il tempo tramite (`time_train`, `time_test`) e il giorno della settimana tramite (`dow_train`, `dow_test`).

Listing 1: Blocco `data`

```
data {
  int<lower=1> N_train;
  int<lower=1> N_test;
  int<lower=1> R;
  int<lower=1> T;
  array[N_train] int<lower=1, upper=R> region_train;
  array[N_train] int<lower=1, upper=T> time_train;
  array[N_train] int<lower=1,upper=7> dow_train;
  array[N_train] real y_log_train;
  array[N_test] int<lower=1, upper=R> region_test;
  array[N_test] int<lower=1, upper=T> time_test;
  array[N_test] int<lower=1,upper=7> dow_test;
  vector[R] pop;
  matrix[R, R] Dmat_space;
}
```

Parametri spaziali. Per definire un dominio informato per ϕ_s, calcoliamo, a partire dalla matrice delle distanze, le distanze minima e massima ammissibili, evitando la diagonale (pari a zero) che falserebbe il calcolo.

Listing 2: Blocco `transformed data`

```
transformed data {
  real phi_s_min;
  real phi_s_max;
  matrix[R, R] Dmat_space_no_diag;

  phi_s_min = 3 / max(Dmat_space);

  Dmat_space_no_diag = Dmat_space;
  for (i in 1:R)
    Dmat_space_no_diag[i, i] = positive_infinity();

  phi_s_max = 3 / min(to_array_1d(Dmat_space_no_diag));
}
```

Parametri. Le quantità latenti spaziali $w_s(s)$ e temporali $w_{s,t}(s,t)$ sono rappresentate da vettori di dimensione R e matrici $R \times T$, rispettivamente. Il parametro α, comune ad ogni AR(1) regionale, viene definito fissando il vincolo sul suo dominio: per garantire la stazionarietà del processo infatti $|\alpha| < 1$. Per garantire la definita positività della matrice di covarianza del processo gaussiano latente, vengono specicati i vincoli di dominio anche per il parametro ϕ_s, precedentemente calcolati.

Listing 3: Blocco `parameters`

```
parameters {
  real mu;
  real<lower=0> sigma2;
  real<lower=-0.99, upper=0.99> alpha;
  matrix[R, T] w_t;
  vector[R] w_s;
  real<lower=phi_s_min, upper = phi_s_max> phi_s;
  real<lower=0, upper=1> rho;
  vector[6] gamma;
  real<lower=0> sigma2_y;
}
```

Vincoli di identificabilità. Poiché il modello è additivo, imponiamo alcuni vincoli per evitare collinearità:

- l'effetto settimanale è centrato: $\gamma_7 = 0$, il settimo giorno funge da baseline;
- la varianza marginale dell'AR(1) deve essere complessivametne coincidente con $\sigma^2 * (1-\rho)$, quindi $\sigma_t^2/(1-\alpha^2) = 1$, per cui σ_t non è stimato direttamente ma calcolato sulla base del vincolo.

Nel blocco transformed parameters, viene inoltre costruita la matrice di covarianza spaziale Σ, utilizzando una funzione esponenziale decrescente $\Sigma_{i,j} = \exp(-\phi_s(Dmat_space)_{i,j})$, dove il parametro ϕ_s è stimato.

Listing 4: Blocco `transformed parameters`

```
transformed parameters {
  vector[7] gamma_ext;
  for (d in 1:6) {
    gamma_ext[d] = gamma[d];
  }
  gamma_ext[7] = 0;

  real<lower = 0> sigma_y = sqrt(sigma2_y);
  real<lower=0> sigma_t = sqrt(1-alpha^2);
  real<lower=0> sigma = sqrt(sigma2);

  matrix[R, R] Sigma_cov;
  for (i in 1:R)
    for (j in 1:R)
      Sigma_cov[i, j] = exp(-phi_s * Dmat_space[i, j]);
}
```

Specificazione del modello. Le prior sono scelte debolmente informative per lasciar emergere la struttura dai dati. L'effetto spaziale è campionato da una distribuzione normale multivariata con covarianza Σ, mentre l'effetto AR(1) è generato ricorsivamente:

- il primo istante è campionato dalla marginale: $w(s,1) \sim \mathcal{N}(0, \frac{\sigma_t^2}{1-\alpha^2})$,
- i successivi dalla distribuzione condizionata: $w(s,t)|w(s,t-1) \sim \mathcal{N}(\alpha * w(s,t-1), \sigma_t^2)$.

Listing 5: Blocco `model`

```
model {
  mu ~ normal(0, 100);
```

```
  sigma2 ~ inv_gamma(1, 1);
  alpha ~ uniform(-1, 1);
  phi_s ~ uniform(phi_s_min, phi_s_max);
  rho ~ beta(1, 2);
  gamma ~ normal(0, 10);
  sigma2_y ~ inv_gamma(1, 1);
  beta ~ normal(1, 100);

  w_s ~ multi_normal(rep_vector(0, R), Sigma_cov);

  for (r in 1:R) {
    w_t[r, 1] ~ normal(0, sigma_t / fmax(sqrt(1 - square(alpha)), 1e-6));
    for (t in 2:T)
      w_t[r, t] ~ normal(alpha * w_t[r, t - 1], sigma_t);
  }

  for (n in 1:N_train) {
    int s = region_train[n];
    int t = time_train[n];
    int d = dow_train[n];
    real mu_y = mu + gamma_ext[d] + sigma *(rho*w_s[s] + (1-rho)* w_t[s, t]) + beta* log(pop[s]);
    y_log_train[n] ~ normal(mu_y, sigma_y);
  }
}
```

Osservazioni implementative. La scelta del processo AR(1) per la componente temporale è stata dettata da un'esigenza di semplificazione computazionale, in quanto consente un'efficiente generazione dei campioni evitando il calcolo dell'inversa di una matrice di covarianza piena, come sarebbe necessario in un processo gaussiano multivariato temporale. Infatti, a livello teorico, entrambi i modelli generano traiettorie autocorrelate, ma il processo AR(1) è computazionalmente più scalabile e meglio supportato in `Stan`.

Quantità derivate. Il blocco `generated quantities` calcola le predizioni logaritmiche sui dati di test e la log-verosimiglianza puntuale per le osservazioni di training, necessaria per il calcolo della WAIC, metrica utile per eventuali confronti con altri modelli.

Listing 6: Blocco `generated quantities`

```
generated quantities {
  array[N_test] real y_log_pred;
  vector[N_train] log_lik;

  for (n in 1:N_test) {
    int s = region_test[n];
    int t = time_test[n];
    int d = dow_test[n];
    real mu_y = mu + gamma_ext[d] + sigma *(rho*w_s[s] + (1-rho)* w_t[s, t]) + beta* log(pop[s]);
    y_log_pred[n] = normal_rng(mu_y,sigma_y);
  }

  for (n in 1:N_train) {
    int s = region_train[n];
    int t = time_train[n];
    int d = dow_train[n];
    real mu_y = mu + gamma_ext[d] + sigma *(rho*w_s[s] + (1-rho)* w_t[s, t]) + beta* log(pop[s]);
    log_lik[n] = normal_lpdf(y_log_train[n] | mu_y, sigma_y);
  }
}
```

5 Risultati e Criticità

In questo paragrafo vengono presentati i risultati ottenuti per ciascuna delle quattro fasi temporali selezionate, con l'obiettivo di indagare le principali problematiche e punti di forza del modello. In particolare, si è scelto di confrontare la capacità predittiva del modello per le varie fasi, tramite metriche e visualizzando il plot delle previsioni, analizzare le catene e i valori stimati a posteriori per i diversi parametri, e infine validare la struttura temporale del modello, calcolando e analizzando i residui dell'AR(1) regionale.

5.1 Previsioni

Per valutare l'efficacia del modello implementato nella previsione dei casi di positività al COVID-19, è utile confrontarne le prestazioni nelle quattro fasi epidemiologiche considerate. Ogni fase presenta caratteristiche proprie in termini di dinamica virale, interventi sanitari, test disponibili e comportamenti sociali. Pertanto, è fondamentale adottare una metrica che consenta un confronto equo tra fasi eterogenee. A tal fine, si è scelto di calcolare una versione normalizzata della Root Mean Squared Error (RMSE), utile per confrontare fasi in cui la scala dei "nuovi positivi" cambia notevolmente. Tale indicatore di accuratezza predittiva è definito come:

$$\mathrm{NRMSE}_{\mathrm{nat}} = \frac{\mathrm{RMSE}}{\overline{y_{\mathrm{obs}}}} = \frac{1}{\overline{y_{\mathrm{obs}}}} \sqrt{\frac{1}{N_{\mathrm{test}}} \sum_{n=1}^{N_{\mathrm{test}}} \left(y_n - \hat{y}_n\right)^2},$$

dove

$$\overline{y_{\mathrm{obs}}} = \frac{1}{N_{\mathrm{test}}} \sum_{n=1}^{N_{\mathrm{test}}} y_n$$

è la media dei "nuovi positivi" osservati nella specifica fase.
In questo modo l'errore diventa adimensionale e interpretabile come "errore medio in percentuale rispetto alla media dei casi nella fase considerata". A livello interpretativo, maggiore è il NRMSE peggiore è la capacità predittiva del modello per quella fase. Di seguito è riportata la tabella con i risultati del NRMSE per ogni fase:

Tabella 3: NRMSE per ciascuna fase

Parametro	Fase 1	Fase 2	Fase 3	Fase 4
$NRMSE$	0.8388120138633391	0.6156939798641157	0.2716661628462854	1.0805682396228700

Dalla tabella emerge che la Fase 3 è quella in cui il modello ottiene le migliori performance predittive, con un NRMSE significativamente più basso. Al contrario, la Fase 4 evidenzia la peggior performance, suggerendo una difficoltà del modello nel catturare le dinamiche introdotte da nuove varianti e dalla diffusione dei vaccini. La Fase 1 presenta un NRMSE relativamente alto, che può essere attribuito in parte al numero limitato di osservazioni disponibili in quel periodo (marzo–maggio 2020), rispetto alla durata temporale delle altre fasi, e quindi a stime più instabili dei parametri spazio-temporali. La Fase 2 mostra errori rilevanti, probabilmente legati alla maggiore complessità introdotta dalle misure differenziate per regione (es. zone a colori).
A supporto dell'analisi quantitativa, la Figura 5.1 riporta le mappe delle previsioni per ciascuna fase: osservato, predetto e differenza (scala naturale).

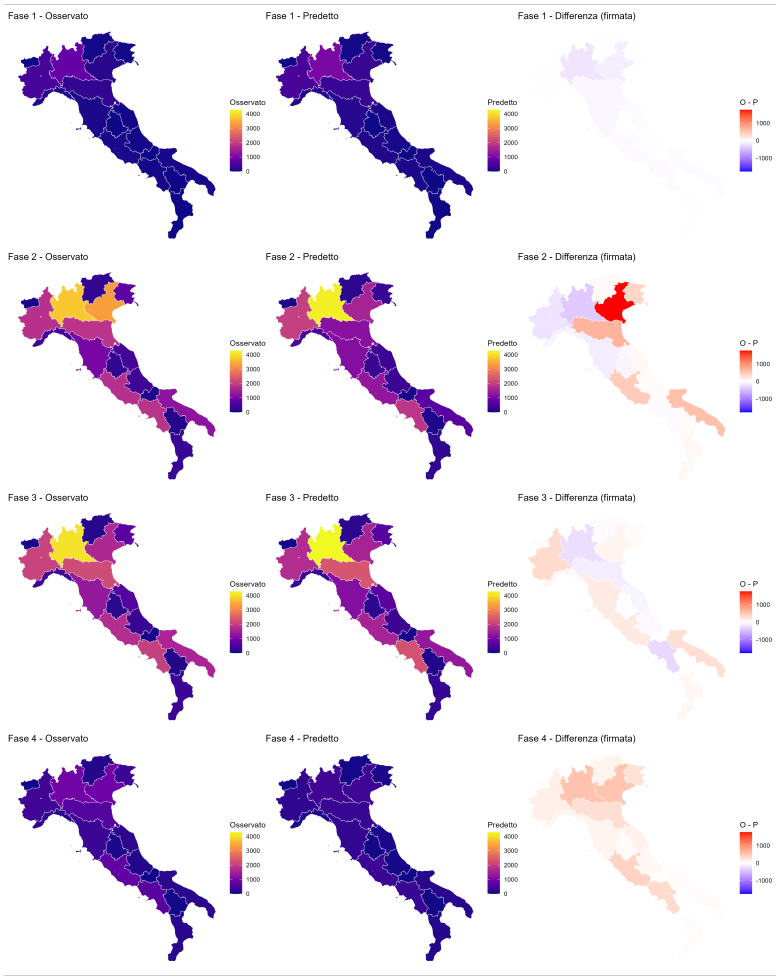

Figura 5.1: Mappa confronto Osservati vs Predetti per ogni fase

Si nota come la Fase 1 sia quella con gli errori meno marcati, come dimostrano le mappe osservata e predetta, molto simili visivamente in tutte le regioni. Sembrerebbe in contraddizione con il fatto che la Fase 1 presenti il secondo NRMSE più alto, ma tale risultato può essere attribuito al fatto che le mappe descrivono l'errore predittivo sul valorer medio del numero di casi, commesso per regione, mentre il NRMSE descrive l'errore aggregato medio sul tempo e lo spazio, quindi una mappa visivamente omogenea non implica per forza un NRMSE basso; in altre parole, un errore piccolo ma molto diffuso può penalizzare tanto quanto un grande errore localizzato. In Fase 2, si osservano sottostime sistematiche in diverse regioni del Centro-Nord, in particolare in Veneto, con errori locali marcati. In Fase 3, le differenze tra osservato e predetto sono contenute e ben distribuite, segno di buona calibrazione spaziale e temporale. Infine, nella Fase 4 il modello tende a sottostimare i casi, in particolare in regioni come Lombardia, Veneto, Toscana e Puglia, caratterizzate sfumature rosa nella mappa delle differenze. Tuttavia, l'entità degli errori non è estrema (assenza di rossi/blu accesi). Un'ulteriore osservazione qualitativa, supportata dalla Figura 5.1, è che le regioni del Sud Italia tendono a presentare errori di previsione inferiori rispetto a molte regioni del Nord. Questo risultato, coerente in diverse fasi, può avere diverse spiegazioni: una minore variabilità interna tra le regioni meridionali, una dinamica epidemica più regolare e posticipata, e una pressione sanitaria meno accentuata, che potrebbe aver garantito una maggiore coerenza nei dati osservati. Questo rafforza ulteriormente l'ipotesi che l'introduzione di covariate esplicative regionali possa migliorare la capacità predittiva soprattutto per

le regioni del Centro-Nord.
Si osservano differenze significative anche nei tempi computazionali, riportati di seguito:

Tabella 4: Tempi computazionali per ciascuna fase, in secondi

Parametro	Fase 1	Fase 2	Fase 3	Fase 4
Tempo	4917.8	15189.1	12501.2	21473

L'aumento dei tempi di esecuzione per fasi successive è coerente sia con la maggiore quantità di dati, sia con la crescente complessità nella struttura latente da apprendere. In particolare, la Fase 4 potrebbe richiedere maggiore sforzo computazionale anche per la presenza di dinamiche non modellate esplicitamente, a causa dell'avvento delle varianti Alpha e Delta.
Infine, si propone un'analisi puntuale di alcuni esempi di previsione rappresentativi per la Fase 2 e la Fase 4, ovvero le più problematiche se si fa riferimento alla mappa 2.1.

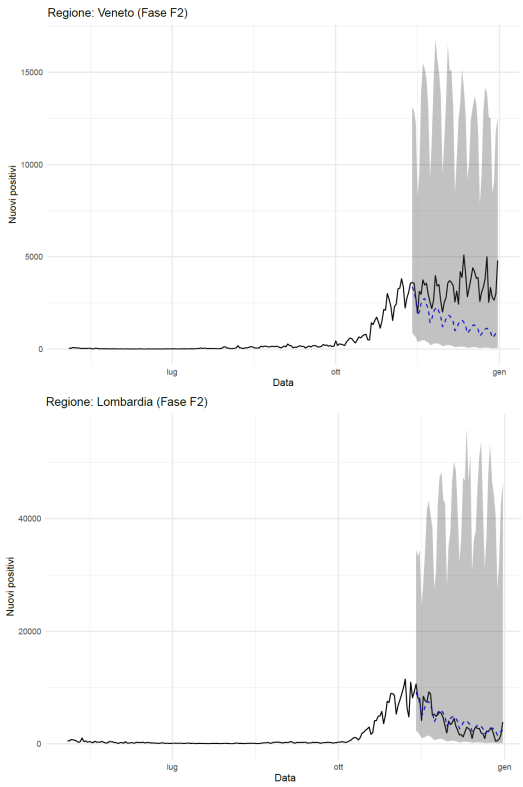

Figura 5.2: Caso peggiore e caso migliore per Fase 2: Veneto (sopra) e Lombardia (sotto).

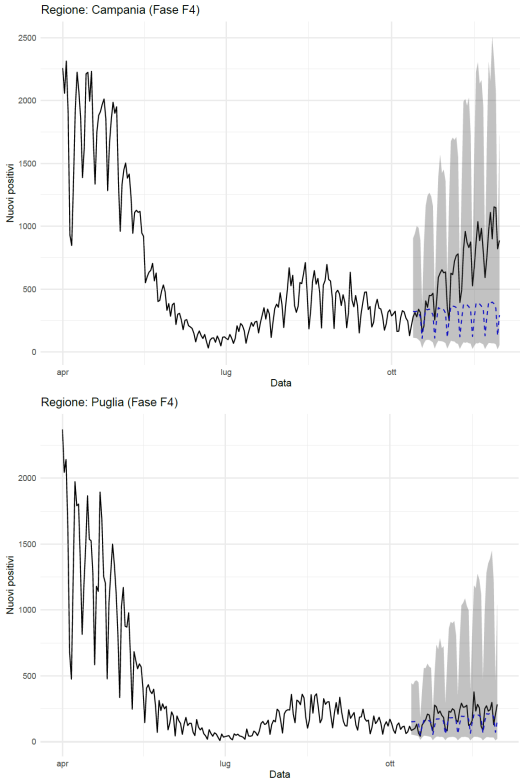

Figura 5.3: Caso peggiore e caso migliore per Fase 4: Campania (sopra) e Puglia (sotto).

Le Figure 5.2 e 5.3 mostrano rispettivamente le previsioni per il caso peggiore e il caso migliore in ciascuna fase. È opportuno ricordare che il modello è stato stimato sulla scala logaritmica della variabile risposta; pertanto, gli intervalli di previsione sono stati inizialmente calcolati nella scala trasformata e successivamente riportati nella scala naturale tramite contro-trasformazione. Sebbene ciò renda gli intervalli asimmetrici, la copertura di probabilità rimane correttamente conservata. Dall'analisi emerge come la struttura del modello, se da una parte include un processo spaziale latente che promuove somiglianze tra regioni vicine, dall'altra parte non riesce a cogliere dinamiche regionali indipendenti, soprattutto nei casi in cui le regioni mostrano traiettorie divergenti rispetto ai territori

limitrofi. In particolare, nella Fase 2, il modello fatica a catturare il comportamento del Veneto, che mostra un andamento crescente dei contagi verso la fine del periodo, in controtendenza rispetto ad altre regioni del Nord, come Lombardia, Liguria, Trentino-Alto Adige, dove si osserva una flessione. La struttura autoregressiva temporale, non differenziata per regione (l'iperparametro α è unico) e la dipendenza spaziale, impediscono al modello di individuare queste asincronie locali, privilegiando una media temporale che penalizza le regioni fuori fase. Questo porta a una sottostima sistematica o a una errata caratterizzazione del trend nei territori non allineati. Una dinamica simile si osserva anche nella Fase 4, dove il modello riesce a cogliere abbastanza bene il comportamento di regioni come Puglia, Calabria e Basilicata, che presentano andamenti simili e più stabili. Al contrario, in Campania, dove i contagi crescono in modo più marcato, il modello non riesce a seguire il trend reale e tende a sottostimare in modo persistente. Anche in questo caso, la combinazione di struttura spaziale e autoregressiva uniforme si dimostra limitante in presenza di divergenze locali. Queste osservazioni rafforzano l'ipotesi che il modello potrebbe beneficiare dell'introduzione di ulteriori covariate regionali (es. numero di tamponi effettuati, mobilità, politiche sanitarie locali), nonché di una maggiore flessibilità nei parametri temporali (es. α regionale o variabile nel tempo), al fine di cogliere comportamenti disomogenei tra regioni, anche se contigue.

5.2 Stime dei parametri a posteriori

Procediamo ora con l'analisi della tabella sottostante, che riporta i valori delle medie a posteriori stimate per i parametri del modello nelle varie fasi.

Tabella 5: Stime posteriori dei parametri (Media ± Dev. Std) per ciascuna fase

Parametro	Fase 1	Fase 2	Fase 3	Fase 4
μ	-11.10 ± 2.53	-10.10 ± 2.43	-9.95 ± 1.46	-10.60 ± 1.94
σ_y^2	0.387 ± 0.024	0.315 ± 0.009	0.108 ± 0.0047	0.201 ± 0.0052
γ_1	-0.549 ± 0.083	-0.380 ± 0.035	-0.508 ± 0.035	-0.976 ± 0.028
γ_2	-0.371 ± 0.085	-0.225 ± 0.036	-0.163 ± 0.035	-0.187 ± 0.028
γ_3	-0.303 ± 0.089	0.004 ± 0.036	0.174 ± 0.034	0.155 ± 0.028
γ_4	0.011 ± 0.090	0.101 ± 0.037	0.171 ± 0.034	0.140 ± 0.029
γ_5	-0.020 ± 0.089	0.155 ± 0.036	0.208 ± 0.033	0.149 ± 0.028
γ_6	-0.027 ± 0.087	0.098 ± 0.036	0.085 ± 0.034	0.103 ± 0.029
σ^2	2.56 ± 0.83	3.07 ± 0.59	0.458 ± 0.153	1.17 ± 0.23
ρ	0.409 ± 0.113	0.101 ± 0.063	0.226 ± 0.127	0.086 ± 0.064
α	0.951 ± 0.017	0.990 ± 0.001	0.984 ± 0.004	0.989 ± 0.001
ϕ_s	1.05 ± 1.36	3.22 ± 1.69	2.91 ± 1.74	3.14 ± 1.73
β	1.06 ± 0.17	0.974 ± 0.17	1.12 ± 0.103	1.08 ± 0.14

Si nota subito come il parametro μ risulti essere molto negativo, e quindi molto piccolo su scala esponenziale, per tutte e 4 le fasi. Questo suggerisce che non esiste una media nazionale significativa in log-scala che possa rappresentare bene tutte le regioni e tempi. In altre parole, gran parte dell'informazione predittiva nel modello non è contenuta nell'intercetta globale, ma nei termini specifici per regione, tempo e popolazione.
Il parametro σ_y^2 coincide con la variabilità globale dei log-contagi. Rappresenta quanto variano i dati attorno alla media prevista dal modello. Si può notare come nella fase 3 e 4 sia molto minore, rispetto a fase 2 e fase 1. Questo pattern è condiviso anche dal parametro σ^2, che rappresenta la varianza latente del processo spazio-temporale, comune ai due effetti.
Per quanto riguarda gli effetti fissi giornalieri γ_d, occorre ricordare che domenica è assunta come gior-

no di riferimento (baseline), quindi ogni coefficiente γ_d rappresenta lo scostamento medio, in scala logaritmica, del numero di casi rispetto alla domenica. Valori negativi indicano un numero medio di casi inferiore rispetto alla domenica, mentre valori positivi indicano un numero superiore. L'entità del coefficiente esprime l'intensità dello scostamento. Si noti inoltre che per comprendere a pieno la loro influenza sul numero dei casi è necessario calcolare l'esponenziale dei coefficienti, perchè la media è in formato logaritmico. In tutte le fasi si osserva un pattern settimanale ben definito: il lunedì è sistematicamente il giorno con meno casi riportati, verosimilmente a causa del ritardo nella registrazione durante il weekend. Il martedì mostra ancora un livello inferiore rispetto alla domenica, ma con un effetto attenuato. A partire dal mercoledì, i casi aumentano progressivamente, con un picco intorno a giovedì e venerdì. Questo schema si mantiene stabile nel tempo, pur con variazioni nell'intensità degli effetti tra le diverse fasi. In particolare, nella Fase 4 si osserva un'accentuazione della differenza, con il valore più negativo del lunedì ($\gamma_1 = -0{,}976$), compatibile con una maggiore pressione sui sistemi di tracciamento e notifica durante i momenti critici della pandemia. Nel complesso, i coefficienti γ_d confermano la presenza di un forte pattern settimanale nei dati.
Procediamo ora con l'interpretazione del valore medio a posteriori stimato per il parametro ρ, che modula il peso relativo tra la componente spaziale e quella temporale. Si può osservare che nella fase 1 $\rho \approx 0.41$, suggerendo che entrambi gli effetti sono importanti. Dopodichè, a partire dalla fase F2, il valore di ρ subisce una drastica diminuzione, rivelando che nelle fasi successive il modello attribuisce una maggiore importanza alle variazioni temporali (effetto AR(1) per regione) rispetto alla struttura spaziale statica.
Questa interpretazione è rafforzata anche dal parametro α, che regola la persistenza temporale nei trend regionali. Infatti, in tutte le fasi $\alpha \in [0.95, 0.99]$, indicando forte dipendenza temporale: i contagi in una regione dipendono fortemente dal valore del giorno prima.
Per quanto riguarda il parametro di decay ϕ_s, ricordiamo che governa la velocità del decadimento della correlazione con la distanza: un "decay" alto significa che la correlazione si riduce molto rapidamente con la distanza, documentando che le regioni più distanti sono fondamentalmente indipendenti, mentre un valore basso significa che la correlazione si riduce più lentamente. Si nota un forte aumento a partire dalla fase F2 del valor medio stimato, suggerendo quindi una dipendenza localizzata, in quanto le correlazioni spaziali si attenuano più rapidamente con la distanza.
Infine, il coefficiente β associato alla popolazione logaritmica viene stimato vicino a 1 in tutte le fasi, come atteso, suggerendo una proporzionalità lineare tra popolazione e numero di casi.
Dall'analisi dei traceplots dei parametri nelle diverse fasi, si è osservato che in generale i parametri di $\mu, \gamma, \beta, \sigma_y^2$ sono andati più facilmente a convergenza, e per questi le due catene erano fondamentalmente sovrapposte, mentre sono emerse criticità ricorrenti relativamente ai parametri latenti σ^2e ρ, fortemente collegati perchè la prima è la varianza latente del processo spazio-temporale, mentre il secondo è parametro responsabile di misurare il peso di ciascun effetto, ovvero quanto della varianza σ^2 viene spiegata dal processo spaziale e quanta dal processo temporale. Le principali problematiche individuate sono:

1. **Mancata sovrapposizione tra le catene:** in particolare nelle fasi 2 e 4 si osserva che le due catene tendono a esplorare regioni differenti dello spazio dei parametri, con scarsa sovrapposizione. Questo comportamento è indicativo di una scarsa convergenza: le catene non sembrano essersi stabilizzate attorno a una stessa distribuzione stazionaria. Di conseguenza, le stime ottenute in queste fasi sono potenzialmente poco affidabili.

2. **Alta varianza posteriore:** in tutte le fasi analizzate si osservano oscillazioni ampie nelle catene, che indicano una difficoltà del modello nel localizzare i parametri con precisione. Questo riflette un'incertezza strutturale legata al modello stesso e non solamente a problemi di campionamento: anche le fasi 1 e 3, pur mostrando una sovrapposizione migliore tra le catene, soffrono di una marcata esplorazione di un ampio range di valori plausibili.

Nel complesso, le fasi 2 e 4 risultano maggiormente affette da problemi di convergenza delle catene, mentre le fasi 1 e 3 evidenziano soprattutto una maggiore incertezza nella localizzazione dei parametri. Tali problematiche riflettono in parte la complessità del modello, ma anche le scelte implementative, come l'assunzione di separabilità tra spazio e tempo, che può rivelarsi limitante in contesti in cui la struttura latente dei dati non supporta una chiara distinzione tra le due dimensioni. Per visualizzare le problematiche, di seguito sono riportati i traceplots dei parametri per Fase 1 e Fase 2.

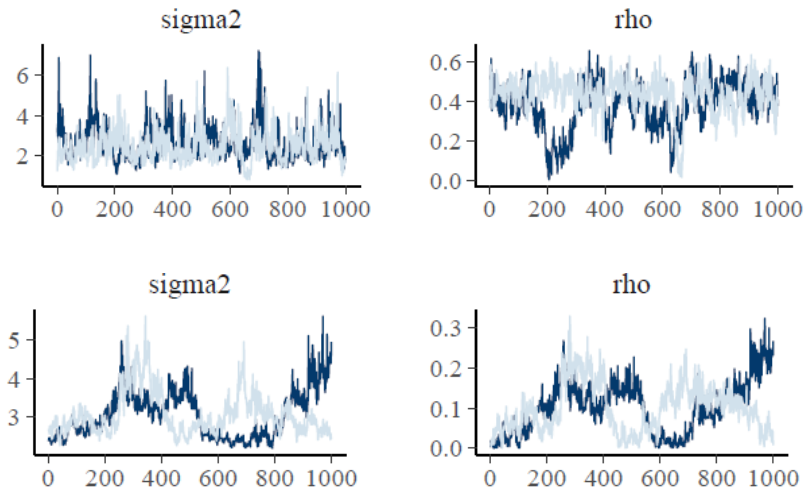

Figura 5.4: Traceplot per F1 e F2

5.3 Analisi dei residui del processo temporale latente

Nel modello bayesiano implementato, la dinamica temporale per ciascuna regione s è modellata tramite un processo latente $w_{s,t}(s,t)$ autoregressivo di ordine 1. Non essendo $w_{s,t}(s,t)$ direttamente osservabile, si procede all'analisi dei residui del processo AR(1) latente utilizzando le stime posteriori ottenute dal fitting bayesiano. Per ogni regione s e tempo $t > 1$, si definiscono i residui come:

$$r_t^{(s)} = \hat{w}(s,t) - \hat{\alpha} \cdot \hat{w}(s,t-1)$$

dove $\hat{w}(s,t)$ è la stima a posteriori dell'effetto latente e $\hat{\alpha}$ è la stima a posteriori del coefficiente autoregressivo. L'obiettivo è verificare che tali residui siano compatibili con un processo white noise, per cui devono essere verificate le seguenti condizioni:

- **Media nulla:** $\mathbb{E}[r_t^{(s)}] = 0$
- **Varianza costante:** $\mathrm{Var}[r_t^{(s)}] = \sigma^2$, costante nel tempo
- **Indipendenza:** le componenti $r_t^{(s)}$ sono indipendenti nel tempo
- **Autocorrelazione nulla:** l'autocorrelazione (ACF) e l'autocorrelazione parziale (PACF) devono essere nulle per ogni lag $k \geq 1$. Ricordiamo che l'ACF misura la correlazione tra i residui a diversi ritardi temporali (lag), mentre la PACF quantifica la correlazione parziale, cioè la correlazione tra la serie e i suoi lag una volta rimossi gli effetti intermedi. Un plot dell'ACF o PACF è detto correlogramma e permette di identificare la struttura di dipendenza temporale residua non catturata dal modello.

E' stata effettuata un'analisi qualitativa e comparativa dei residui per le 4 fasi temporali, nell'ottica di verificare se il processo latente $w(s,t)$ segua effettivamente una dinamica AR(1) ben specificata. Osservando i risultati, sono state individuate problematiche comuni ad ogni fase, anche se con frequenza diversa, probabilmente per via delle differenti dinamiche di contagio sottostanti. In particolare in tutte le fasi è emersa la problematica legata alla multimodalità della funzione di densità dei residui per le varie regioni: accanto al picco principale, simmetrico e centrato in zero, si osservano uno o più picchi secondari meno pronunciati. La causa di ciò può essere ricondotta al fatto che la medesima fase può essere stata soggetta a dinamiche miste di diversa portata all'interno dell'intervallo temporale, per cui l'AR(1) cerca di mediare su un comportamento non completamente uniforme nel tempo. Ad esempio, all'inizio della Fase 1, si registra un aumento dei casi, seguito da una diminuzione nella parte finale dell'itervallo, sintomo dell'efficacia del lockdown. Similmente, si può giustificare la presenza di multimodalità nella Fase 3 come un tentativo del modello di adattarsi a una velocità di contagio influenzata dall'introduzione della vaccinazione, che contrasta la diffusione dei casi. Di seguito si riportano esempi visivi relativi alle regioni Veneto nella fase 1 e Toscana nella fase 3.

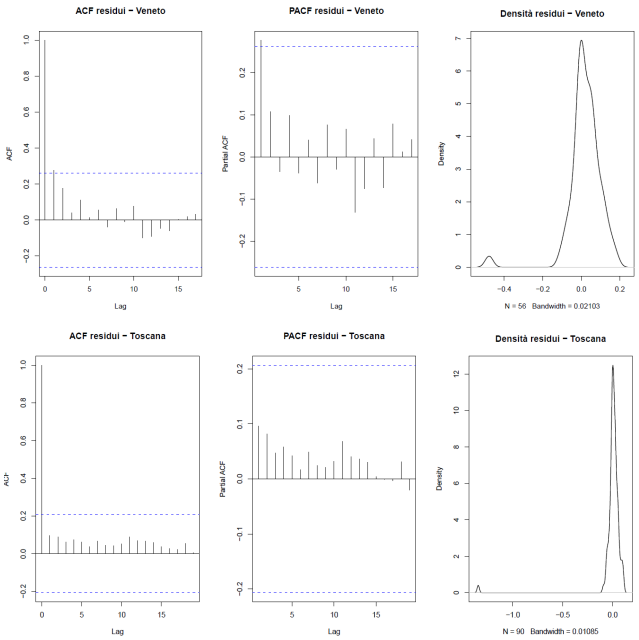

Figura 5.5: Esempi di bimodalità per Veneto (Fase 1) e Toscana (Fase 3).

Per quanto riguarda le altre statistiche di interesse, in contemporanea alla multimodalità, si sono osservate acf e pacf fuori dalle bande, indicando strutture temporali mal catturate. Tali problematiche, pur coinvolgendo anche fasi 1 e 3, compaiono in maggior misura nelle fasi 2 e 4, ovvero quelle con le dinamiche temporali più complesse, a causa della suddivisione a colori e dell'avvento delle varianti Alpha e Delta. Di seguito sono presentati alcuni esempi rappresentativi:

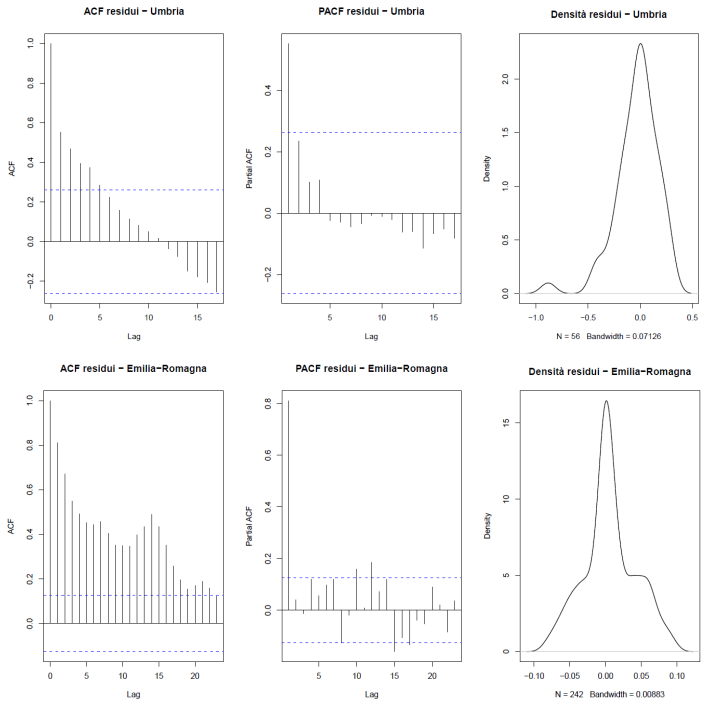

Figura 5.6: Esempi di ACF e PACF non nulle per F1 e F2.

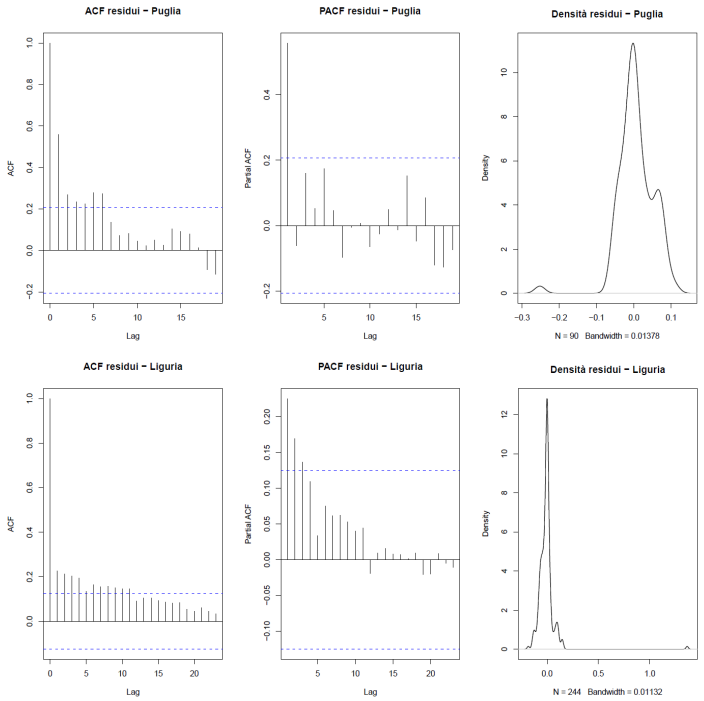

Figura 5.7: Esempi di ACF e PACF non nulle per F3 e F4.

A livello interpretativo, la PACF dà una stima dell'ordine minimo dell'AR. Ad esempio, la presenza di autocorrelazione parziale significativa fino a lag 3, come nel grafico della Liguria nella fase 4, suggerisce che un AR(3) potrebbe spiegare meglio la serie latente. Questo vale solo se anche l'ACF si azzera dopo pochi lag, altrimenti potrebbero servire modelli più complessi, come l' ARMA(p,q).

5.4 Limiti del modello e miglioramenti futuri

Uno dei principali ostacoli riscontrati nell'implementazione del modello è rappresentato dagli elevati tempi computazionali, dovuti sia alla dimensionalità elevata del dataset sia alla complessità del modello implementato. Nel nostro caso specifico, l'introduzione di un processo autoregressivo di ordine 1 per ciascuna delle 19 regioni, combinato con una struttura spaziale, ha comportato tempi di esecuzione particolarmente elevati. Questo è in parte dovuto alla necessità di invertire la matrice di covarianza Σ_{Cov}, un'operazione computazionalmente onerosa, la cui complessità teorica cresce come $O(n^{3/2})$. Sebbene in Stan l'inversione sia ottimizzata tramite l'uso diretto del comando multi_normal, che attua implicitamente la decomposizione di Cholesky per invertire la matrice, rimane comunque un collo di bottiglia. Per gestire parzialmente tale problematica, si potrebbe intervenire sulla struttura spaziale del modello, assumendo un'ipotesi più leggera come quella del Nearest Neighbour Gaussian Process (NNGP). Infatti si è osservato che in generale la dipendenza spaziale è meno influente rispetto a quella temporale, pertanto tale approccio, basato su una nozione di vicinato discreto piuttosto che sulla distanza continua, consentirebbe di ridurre significativamente i costi computazionali, mantenendo una buona accuratezza nella stima. Se da una parte si sceglie di semplificare la struttura spaziale latente del modello, dall'altra pensare di complicare quella temporale, magari utilizzando un modello ARMA(p,q) potrebbe migliorare le performance predittive, soprattutto nelle fasi 2 e 4. D'altra parte, la marcata eterogeneità osservata tra le regioni in alcune fasi, sebbene vicine, evidenzia l'importanza di differenziare maggiormente le dinamiche regionali, per esempio tenendo conto di altre covariate locali, come il numero di tamponi giornaliero per regione o introducendo un coefficiente autoregressivo α per ogni regione.

Un altro limite del modello, è legato alla semplificazione strutturale adottata: l'assunzione di separabilità tra la componente spaziale e quella temporale. Tale ipotesi, che consente di esprimere la covarianza spazio-temporale come prodotto tra una matrice spaziale e una temporale, semplifica l'implementazione e consente l'introduzione di un parametro ρ in grado di bilanciare l'importanza relativa delle due dimensioni. Tuttavia, questa scelta comporta una perdita di flessibilità, in quanto esclude a priori qualsiasi forma di interazione tra spazio e tempo. In particolare, il modello assume che le dinamiche temporali siano identiche in ogni area geografica, e che la dipendenza spaziale resti costante nel tempo. Questo può risultare troppo restrittivo per rappresentare fenomeni reali in cui, ad esempio, l'evoluzione temporale di un processo varia da regione a regione, o si osservano picchi asincroni nel tempo. La separabilità, quindi, sebbene utile per contenere la complessità, può compromettere la capacità del modello di catturare correttamente le dinamiche spazio-temporali più complesse.

Nel complesso, pur con le sue limitazioni, il modello ha permesso di ottenere delle buone previsioni dei dati di contagio. Tuttavia, le criticità emerse evidenziano la necessità di modelli più flessibili e scalabili, in grado di cogliere con maggiore precisione le dinamiche spazio-temporali complesse. Le modifiche proposte rappresentano un naturale sviluppo del lavoro, orientato a migliorare sia l'efficienza computazionale che la qualità dell'inferenza.